

Exercice 1 : parmi les traitements suivants, quels sont ceux qui sont facile à formaliser , difficiles à formaliser, pratiquement impossibles à formaliser ? argumentez votre réponse.

Le critère est la possibilité de décrire le traitement par un algorithme précis, déterministe et non ambigu, exécutable mécaniquement. Plus un traitement dépend de la compréhension du sens, du contexte ou du jugement humain, plus il devient difficile — voire impossible — à formaliser.

Faciles à formaliser

Ces traitements se réduisent à des règles claires ou à des manipulations de symboles.

(b) Supprimer le texte entre parenthèses. Règle simple : repérer chaque « (», la «) » correspondante, effacer ce qui est entre les deux. Pure manipulation de caractères, sans interprétation.

(d) Trouver le jour de la semaine du 2 octobre connaissant celui d'aujourd'hui. Il suffit de compter le nombre de jours qui séparent aujourd'hui du 2 octobre, puis de prendre ce nombre modulo 7. Calcul purement arithmétique et déterministe.

(i) Conjuguer un verbe. La conjugaison suit des règles grammaticales finies (terminaisons par groupe, temps, personne) complétées par des tables d'exceptions pour les verbes irréguliers. Tout est codifiable.

(j) Trier une liste de noms. C'est l'exemple type de l'algorithme (ordre alphabétique = comparaison de chaînes). Problème entièrement résolu et formalisé.

(f) Détecter les fautes d'orthographe. Pour l'essentiel, on compare chaque mot à un dictionnaire : s'il n'y figure pas, il est signalé. C'est ce que font les correcteurs. Nuance : les fautes qui donnent un mot existant mais faux dans le contexte (« a » / « à », « ces » / « ses ») échappent à cette approche lexicale et relèvent, elles, de la catégorie difficile.

Difficiles à formaliser

Ils nécessitent une analyse du langage ou du contexte, avec de l'ambiguïté à lever.

(a) Compter les formes verbales d'un document. Il faut d'abord identifier quels mots sont des verbes, ce qui suppose une analyse grammaticale et la levée d'ambiguïtés (« ferme », « porte », « courant » peuvent être verbe, nom ou adjectif selon la phrase). Faisable approximativement, rarement parfaitement.

(c) Traduire la notice d'une machine. La traduction exige de comprendre le sens puis de le reformuler dans une autre langue. Le domaine technique (vocabulaire restreint, contenu factuel) la rend plus abordable qu'une traduction littéraire, mais la machine reste imparfaite : c'est difficile, non trivial.

(e) Remplir une grille de mots croisés avec les définitions. Le respect des contraintes de lettres croisées est un problème formalisable ; mais interpréter les définitions (souvent allusives ou à double sens) pour trouver le bon mot demande une compréhension sémantique, ce qui est le vrai obstacle.

(g) Corriger les fautes d'orthographe. Détecter qu'un mot est faux est une chose (voir (f)) ; choisir la bonne correction en est une autre, car il faut deviner le mot voulu à partir du contexte (« il vou l'a dit » → « vous » ? « voue » ? « vaut » ?). Le choix contextuel est difficile à automatiser sûrement.

Pratiquement impossibles à formaliser

Ils reposent sur la compréhension profonde, la créativité ou le jugement, sans règle qui garantisse un « bon » résultat.

(h) Écrire une dissertation. Cela demande de comprendre un sujet, de bâtir une argumentation originale, de nuancer et de soigner le style. Il n'existe aucun algorithme qui produise, à coup sûr, une dissertation pertinente et convaincante — et la qualité elle-même est un jugement subjectif.

(k) Résumer un texte. Résumer suppose de comprendre le texte, de hiérarchiser l'important et de reformuler fidèlement. Ce qui est « essentiel » relève de l'interprétation : deux personnes produisent des résumés différents, tous deux valables. Pas de règle mécanique unique.

(l) Conduire une voiture. Il faut percevoir un environnement imprévisible, interpréter des situations infiniment variées et décider en temps réel, avec des enjeux de sécurité. Malgré les progrès des véhicules autonomes, cela ne se ramène pas à un algorithme simple et fiable en toutes circonstances.

Fil directeur : on passe du syntaxique (manipulation de symboles selon des règles → facile) au sémantique (dépendant du sens et du contexte → difficile), puis au jugement / perception du monde réel (créativité, situations ouvertes → pratiquement impossible). Les paires (f)/(g) et le trio (a)/(c)/(k) illustrent bien ce glissement progressif.

Note : l'apprentissage automatique a fait apparaître une catégorie intermédiaire : des tâches qu'on ne sait toujours pas décrire par des règles, mais qu'on sait désormais approximer en apprenant des régularités dans des données. Résumer, traduire, corriger l'orthographe en contexte, et même une bonne part de la conduite (l) tombent là-dedans. La vieille frontière a donc été redessinée — non pas parce que ces tâches sont devenues « formalisables » au sens ancien, mais parce qu'un autre mode d'automatisation a émergé.

Exercice 2 : quelques questions de réflexion...

- (a) Si on vous demande, à vous être humain, les anagrammes du mot CRANE, que proposerais-tu comme réponse ? Que serait capable de faire un « ordinateur » face à la même situation ?

L'humain : ne va pas énumérer méthodiquement toutes les combinaisons : il pioche dans son vocabulaire les mots qui utilisent les lettres C, R, A, N, E et qui veulent dire quelque chose. Il proposerait : NACRE (la matière brillante des coquillages), ANCRE (celle du bateau), ÉCRAN (en négligeant l'accent, ce sont bien les mêmes lettres), RANCE (un beurre rance), CARNE (familier, une mauvaise viande ou un vieux cheval)

La machine : Sa force est exactement inverse. Il sait faire une chose que je ne peux pas faire de tête : générer mécaniquement les 120 permutations possibles des cinq lettres, sans en oublier une seule, en une fraction de seconde. C'est une tâche purement syntaxique — de la manipulation de symboles selon une règle — donc parfaite pour lui. Mais ces 120 chaînes sont en immense majorité du charabia (RECAN, NERAC, ACREN...). L'ordinateur, seul, n'a aucune idée de ce qui est un vrai mot : la lettre « E » ne « signifie » rien pour lui. Pour qu'il soit utile, **il faut lui adjoindre un dictionnaire** : il génère alors les 120 permutations puis ne garde que celles qui figurent dans la liste des mots français. À ce moment-là il devient supérieur à l'humain — il est à la fois exhaustif et filtré, il ne ratera aucun anagramme valide.

- (b) Que penses-tu de cette définition d'un « mot » :

Une suite de caractères non vide qui :

- *commence le texte ou est précédé d'un caractère délimiteur,*
- *termine le texte ou est suivi d'un caractère délimiteur,*
- *ne contient aucun caractère délimiteur*

Les caractères délimiteurs sont : le guillemet, le point, le point d'interrogation, le point d'exclamation, les deux points, le point virgule, la virgule, les parenthèses, le tiret, l'espace.

Peux-tu donner des exemples de mots que tu connais qui ne collent pas avec cette définition ?

Le problème vient surtout du tiret et de l'apostrophe.

Le tiret est délimiteur, or beaucoup de vrais mots français en contiennent :

arc-en-ciel serait découpé en trois « mots » : arc, en, ciel.

c'est-à-dire, peut-être, vingt-deux, rendez-vous, porte-monnaie, week-end subiraient le même sort.

L'apostrophe n'est pas dans la liste des délimiteurs : conséquence inverse, l'homme, aujourd'hui ou j'aime ne sont pas coupés à l'apostrophe. Selon la définition, aujourd'hui passe pour un seul mot (ce qui est d'ailleurs correct ici), mais l'homme compterait aussi pour un seul mot, alors qu'on y voit intuitivement l'article l' + homme. La définition traite l'apostrophe de façon incohérente avec le tiret.

Autre cas : les nombres et abréviations avec point. Comme le point est délimiteur, 3.14, etc. ou M. sont coupés (3 et 14 séparés ; etc isolé du point). Et un mot collé à sa ponctuation,

comme dans « fini. », est bien isolé — ça, ça marche — mais « U.S.A. » explose en trois fragments.

À l'inverse, peux-tu concevoir des mots à partir de cette définition qui ne sont pas des mots au sens habituel ?

À l'inverse, la définition dit « mot » à toute suite de caractères non délimiteurs, même si elle ne veut rien dire :

- Dans « il a dit xqzptfk », la suite xqzptfk est un « mot » parfaitement valide au sens de la définition — c'est du charabia.
- 42, #@%, abc123, lkjhgf : tous acceptés, aucun n'est un mot de la langue.
- Une faute de frappe comme bonjuor est reconnue comme un mot.

C'est exactement le point de l'exercice sur les anagrammes : la machine, avec cette règle, sait isoler des blocs de caractères (tâche syntaxique, facile à formaliser) mais ne sait pas si le bloc a un sens (tâche sémantique). Pour ça, il lui faudrait, comme pour CRANE, un dictionnaire externe.